

IFT 615 – Intelligence Artificielle

Raisonnement probabiliste

Inférences avec une distribution conjointe et classifieur bayésien naïf


Professeur: Froduald Kabanza

Assistants: D'Jeff Nkashama

Motivation



Détection de pourriels
Classification de documents

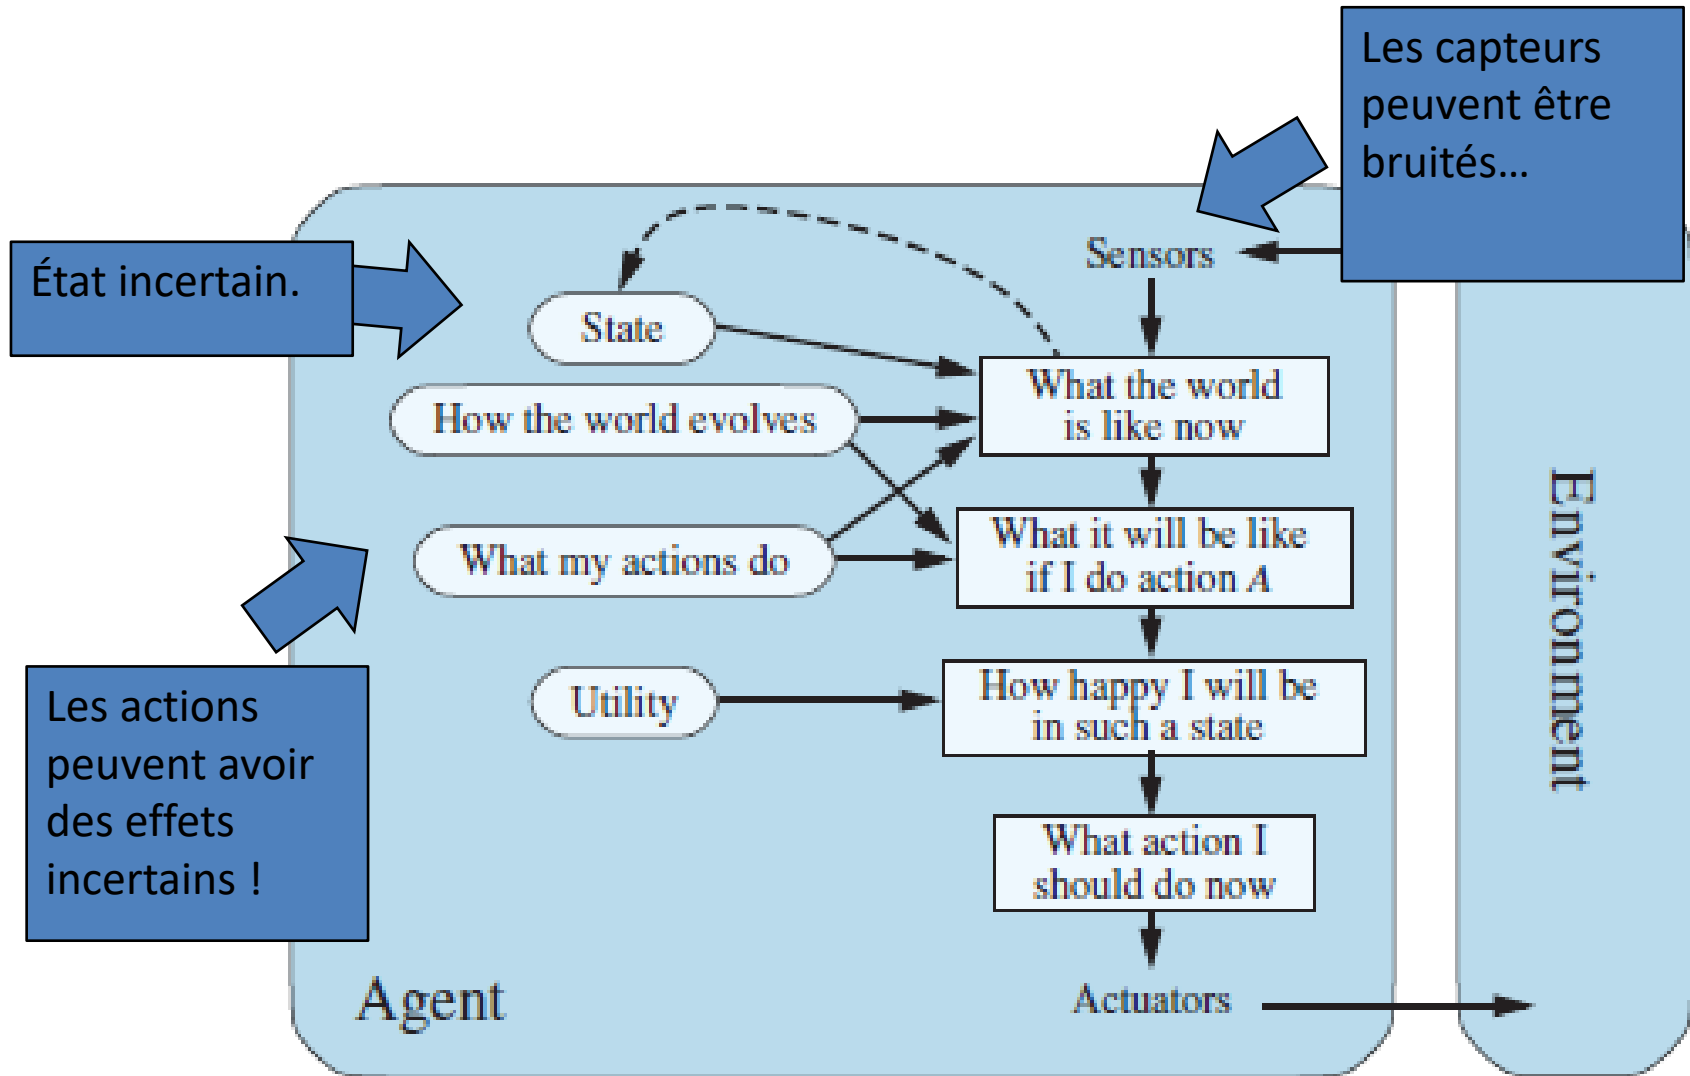


Assurance de dommages



Localisation robotique

Utility-based agents



Théorie des probabilités en IA

- Permet de modéliser la vraisemblance d'événements
 - ◆ l'information sur la vraisemblance est dérivée
 - » des croyances/certitudes d'un agent, ou
 - » d'observations empiriques de ces événements
- Donne un cadre théorique pour mettre à jour la vraisemblance d'événements après l'acquisition d'observations
- Facilite la modélisation en permettant de considérer l'influence de phénomènes complexes comme du « bruit »

Decision-Theoretic Agent



function DT-AGENT(*percept*) **returns** an *action*

persistent: *belief_state*, probabilistic beliefs about the current state of the world
action, the agent's action

update *belief_state* based on *action* and *percept*

calculate outcome probabilities for actions,

 given action descriptions and current *belief_state*

select *action* with highest expected utility

 given probabilities of outcomes and utility information

return *action*

Figure 12.1 A decision-theoretic agent that selects rational actions.

Sujets couverts

- Inférence probabiliste avec une distribution conjointe
- Classifieur bayésien naïf

Exemple – Détection de pourriels

- On souhaite raisonner sur la possibilité qu'un courriel soit un pourriel tenant compte de l'incertitude associée à une telle classification
- Pour ce faire, notre modèle (« base de connaissances ») est une **distribution conjointe des probabilités** de variables aléatoires
 - ◆ **Inconnu** : l'adresse de l'expéditeur n'est pas connue du destinataire
 - ◆ **Sensible** : le courriel contient un mot sensible
 - ◆ **Pourriel** : le courriel est un pourriel

	<i>Inconnu = vrai</i>		<i>Inconnu = faux</i>	
	<i>Sensible = vrai</i>	<i>Sensible = faux</i>	<i>Sensible = vrai</i>	<i>Sensible = faux</i>
<i>Pourriel = vrai</i>	0.108	0.012	0.072	0.008
<i>Pourriel = faux</i>	0.016	0.064	0.144	0.576

Distribution de probabilités

- **Distribution de probabilités** : l'énumération des probabilités pour toutes les valeurs possibles de variables aléatoires

	<i>Inconnu = vrai</i>		<i>Inconnu = faux</i>	
	<i>Sensible = vrai</i>	<i>Sensible = faux</i>	<i>Sensible = vrai</i>	<i>Sensible = faux</i>
<i>Pourriel = vrai</i>	0.108	0.012	0.072	0.008
<i>Pourriel = faux</i>	0.016	0.064	0.144	0.576

- Exemples :

◆ $P(\text{Pourriel}, \text{Inconnu}, \text{Sensible})$

◆ $P(\text{Pourriel}) = [P(\text{Pourriel}=\text{faux}), P(\text{Pourriel}=\text{vrai})] = [0.8, 0.2]$

◆ $P(\text{Pourriel}, \text{Inconnu})$

$$= [[\text{Pourriel}=\text{faux}, \text{Inconnu}=\text{faux}), [\text{Pourriel}=\text{vrai}, \text{Inconnu}=\text{faux})], \\ [\text{Pourriel}=\text{faux}, \text{Inconnu}=\text{vrai}), [\text{Pourriel}=\text{vrai}, \text{Inconnu}=\text{vrai})]]$$

Toutes ces probabilités somment à 1

- La somme est toujours égale à 1
- J'utilise le symbole **P** pour les distributions et *P* pour les probabilités
 - ◆ $P(\text{Pourriel})$ désignera la probabilité $P(\text{Pourriel}=x)$ pour une valeur x non-spécifiée

Probabilité conjointe

- **Probabilité conjointe** : probabilité d'une assignation de valeurs à toutes les variables

◆ $P(\text{Inconnu}=\text{vrai}, \text{Sensible}=\text{vrai}, \text{Pourriel}=\text{vrai}) = 0.108$ (10.8%)

◆ $P(\text{Inconnu}=\text{faux}, \text{Sensible}=\text{faux}, \text{Pourriel}=\text{vrai}) = 0.008$ (0.8%)

	<i>Inconnu = vrai</i>		<i>Inconnu = faux</i>	
	<i>Sensible = vrai</i>	<i>Sensible = faux</i>	<i>Sensible = vrai</i>	<i>Sensible = faux</i>
<i>Pourriel = vrai</i>	0.108	0.012	0.072	0.008
<i>Pourriel = faux</i>	0.016	0.064	0.144	0.576

Probabilité marginale

- **Probabilité marginale** : probabilité sur un sous-ensemble des variables
 - ◆ $P(Y) = \sum_z P(Y, Z=z)$ - Pour n'importe quelle ensemble de variable **Y** et **Z**
 - ◆ $P(\text{Inconnu}=\text{vrai}, \text{Pourriel}=\text{vrai})$
 $= P(\text{Inconnu}=\text{vrai}, \text{Sensible}=\text{vrai}, \text{Pourriel}=\text{vrai}) + P(\text{Inconnu}=\text{vrai}, \text{Sensible}=\text{faux}, \text{Pourriel}=\text{vrai})$
 $= \sum_{x \in \{\text{vrai}, \text{faux}\}} P(\text{Inconnu}=\text{vrai}, \text{Sensible}=x, \text{Pourriel}=\text{vrai}) = 0.108 + 0.012 = \mathbf{0.12}$

	<i>Inconnu = vrai</i>		<i>Inconnu = faux</i>	
	<i>Sensible = vrai</i>	<i>Sensible = faux</i>	<i>Sensible = vrai</i>	<i>Sensible = faux</i>
<i>Pourriel = vrai</i>	0.108	0.012	0.072	0.008
<i>Pourriel = faux</i>	0.016	0.064	0.144	0.576

Probabilité marginale

- **Probabilité marginale** : probabilité sur un sous-ensemble des variables

◆ $P(\text{Pourriel}=\text{vrai})$
 $= \sum_{x \in \{\text{vrai}, \text{faux}\}} \sum_{y \in \{\text{vrai}, \text{faux}\}} P(\text{Inconnu}=x, \text{Sensible}=y, \text{Pourriel}=\text{vrai})$
 $= 0.108 + 0.012 + 0.072 + 0.008 = \mathbf{0.2}$

	<i>Inconnu = vrai</i>		<i>Inconnu = faux</i>	
	<i>Sensible = vrai</i>	<i>Sensible = faux</i>	<i>Sensible = vrai</i>	<i>Sensible = faux</i>
<i>Pourriel = vrai</i>	0.108	0.012	0.072	0.008
<i>Pourriel = faux</i>	0.016	0.064	0.144	0.576

Probabilité d'un événement arbitraire

- Probabilité de disjonction (« ou ») d'événements :

- ◆ $P(\text{Pourriel}=\text{vrai} \text{ ou } \text{Inconnu}=\text{faux})$ – Six états (mondes) possibles

$$= 0.108 + 0.012 + 0.072 + 0.008 + 0.144 + 0.576$$

$$= \mathbf{0.92}$$

- ◆ $P(\text{Pourriel}=\text{vrai} \text{ ou } \text{Inconnu}=\text{faux})$ – Une autre façon de le calculer

$$= P(\text{Pourriel}=\text{vrai}) + P(\text{Inconnu}=\text{faux}) - P(\text{Pourriel}=\text{vrai}, \text{Inconnu}=\text{faux})$$

$$= 1 - P(\text{Pourriel}=\text{faux}, \text{Inconnu}=\text{vrai}) = 1 - 0.016 - 0.064 = \mathbf{0.92}$$

	Inconnu = vrai		Inconnu = faux	
	Sensible = vrai	Sensible = faux	Sensible = vrai	Sensible = faux
Pourriel = vrai	0.108	0.012	0.072	0.008
Pourriel = faux	0.016	0.064	0.144	0.576

Probabilité d'un événement arbitraire

- On peut calculer la probabilité d'événements arbitrairement complexes
 - ◆ il suffit d'additionner les probabilités des événements élémentaires associés
 - ◆ $P((Pourriel=vrai, Inconnu=faux) \text{ ou } (Sensible=faux, Pourriel=faux))$
 $= 0.072 + 0.008 + 0.064 + 0.576 = \mathbf{0.72}$

	<i>Inconnu = vrai</i>		<i>Inconnu = faux</i>	
	<i>Sensible = vrai</i>	<i>Sensible = faux</i>	<i>Sensible = vrai</i>	<i>Sensible = faux</i>
<i>Pourriel = vrai</i>	0.108	0.012	0.072	0.008
<i>Pourriel = faux</i>	0.016	0.064	0.144	0.576

Probabilité conditionnelle

- Probabilité conditionnelle :

- ◆ $P(X|Y) = P(X,Y) / P(Y)$ si $P(Y) \neq 0$

- ◆ $P(\text{Pourriel}=\text{faux} \mid \text{Inconnu}=\text{vrai})$
 $= P(\text{Pourriel}=\text{faux}, \text{Inconnu}=\text{vrai}) / P(\text{Inconnu}=\text{vrai})$
 $= (0.016 + 0.064) / (0.016 + 0.064 + 0.108 + 0.012) = 0.4$

	Inconnu = vrai		Inconnu = faux	
	Sensible = vrai	Sensible = faux	Sensible = vrai	Sensible = faux
Pourriel = vrai	0.108	0.012	0.072	0.008
Pourriel = faux	0.016	0.064	0.144	0.576

Distribution conditionnelle

- On a vu que
 - ◆ $P(Y) = \sum_z P(Y, Z=z)$
 - ◆ $P(X|Y) = P(X,Y) / P(Y)$ si $P(Y) \neq 0$
- On en déduit: $P(Y) = \sum_z P(Y|Z)P(Z=z)$

Distribution conditionnelle

	<i>Inconnu = vrai</i>		<i>Inconnu = faux</i>	
	<i>Sensible = vrai</i>	<i>Sensible = faux</i>	<i>Sensible = vrai</i>	<i>Sensible = faux</i>
<i>Pourriel = vrai</i>	0.108	0.012	0.072	0.008
<i>Pourriel = faux</i>	0.016	0.064	0.144	0.576

- Exemple :

- ◆ $P(\text{Pourriel} \mid \text{Inconnu}=\text{faux})$

- $= [P(\text{Pourriel}=\text{faux} \mid \text{Inconnu}=\text{faux}), P(\text{Pourriel}=\text{vrai} \mid \text{Inconnu}=\text{faux})]$

- $= [0.9, 0.1]$

- ◆ $P(\text{Pourriel} \mid \text{Inconnu})$

- $= [[P(\text{Pourriel}=\text{faux} \mid \text{Inconnu}=\text{faux}), P(\text{Pourriel}=\text{vrai} \mid \text{Inconnu}=\text{faux})],$

- $[P(\text{Pourriel}=\text{faux} \mid \text{Inconnu}=\text{vrai}), P(\text{Pourriel}=\text{vrai} \mid \text{Inconnu}=\text{vrai})]]$

- $= [[0.9, 0.1],$

- $[0.4, 0.6]]$

- **Chaque sous-ensemble de probabilités** associé aux mêmes valeurs des variables sur lesquelles on conditionne somme à 1

- $P(\text{Pourriel} \mid \text{Inconnu})$ contient deux distributions de probabilités sur la variable *Pourriel* : une dans le cas où *Inconnu=faux*, l'autre lorsque *Inconnu=vrai*

Distribution conditionnelle

- Une distribution conditionnelle peut être vue comme une distribution **renormalisée** afin de satisfaire les conditions de sommation à 1

- $P(X|e) = \alpha \sum_y P(X,e,y)$

- Exemple :

- ◆ $P(\text{Pourriel} \mid \text{Inconnu}=\text{vrai})$
 $= \alpha P(\text{Pourriel}, \text{Inconnu}=\text{vrai})$
 $= \alpha [0.08, 0.12]$
 $= (1 / (0.08 + 0.12)) [0.08, 0.12]$
 $= [0.4, 0.6]$

	Inconnu = vrai		Inconnu = faux	
	Sensible = vrai	Sensible = faux	Sensible = vrai	Sensible = faux
Pourriel = vrai	0.108	0.012	0.072	0.008
Pourriel = faux	0.016	0.064	0.144	0.576

- ◆ $P(\text{Pourriel} \mid \text{Inconnu})$
 $= [\alpha_{\text{faux}} P(\text{Pourriel}, \text{Inconnu}=\text{faux}),$
 $\alpha_{\text{vrai}} P(\text{Pourriel}, \text{Inconnu}=\text{vrai})]$
 $= [[0.72, 0.08] / (0.72 + 0.08),$
 $[0.08, 0.12] / (0.08 + 0.12)]$
 $= [[0.9, 0.1],$
 $[0.4, 0.6]]$

Règle du produit

- Règle du produit :

- ◆ $P(X,Y)=P(X|Y)P(Y)$

- ◆ $P(\text{Pourriel}=\text{faux}, \text{Inconnu}=\text{vrai})$
 $= P(\text{Pourriel}=\text{faux} \mid \text{Inconnu}=\text{vrai}) P(\text{Inconnu}=\text{vrai})$
 $= P(\text{Inconnu}=\text{vrai} \mid \text{Pourriel}=\text{faux}) P(\text{Pourriel}=\text{faux})$

- ◆ En général :
 $P(\text{Pourriel}, \text{Inconnu}) = P(\text{Pourriel} \mid \text{Inconnu}) P(\text{Inconnu})$
 $= P(\text{Inconnu} \mid \text{Pourriel}) P(\text{Pourriel})$

Règle de chaînage

- Règle du produit :

- ◆ $P(X,Y)=P(X|Y)P(Y)$

- Règle de chaînage (*chain rule*) pour n variables $X_1 \dots X_n$:

- ◆
$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1, \dots, X_{n-1}) P(X_n | X_1, \dots, X_{n-1}) \\ &= P(X_1, \dots, X_{n-2}) P(X_{n-1} | X_1, \dots, X_{n-2}) P(X_n | X_1, \dots, X_{n-1}) \\ &= \dots \\ &= \prod_{i=1..n} P(X_i | X_1, \dots, X_{i-1}) \end{aligned}$$

Règle de chaînage

- La règle du chaînage est vraie, quelle que soit la distribution de $X_1 \dots X_n$
- Plutôt que de spécifier toutes les probabilités jointes $P(X_1, \dots, X_n)$, on pourrait plutôt spécifier $P(X_1)$, $P(X_2|X_1)$, $P(X_3|X_1, X_2)$, ..., $P(X_n | X_1, \dots, X_{n-1})$

	Inconnu = vrai		Inconnu = faux	
	Sensible = vrai	Sensible = faux	Sensible = vrai	Sensible = faux
Pourriel = vrai	0.108	0.012	0.072	0.008
Pourriel = faux	0.016	0.064	0.144	0.576

- Exemple, on aurait pu spécifier :
 - ◆ $P(\text{Pourriel}=\text{faux}) = 0.8$, $P(\text{Pourriel}=\text{vrai}) = 0.2$
 - ◆ $P(\text{Inconnu}=\text{faux} | \text{Pourriel}=\text{faux}) = 0.9$, $P(\text{Inconnu}=\text{vrai} | \text{Pourriel}=\text{faux}) = 0.1$
 $P(\text{Inconnu}=\text{faux} | \text{Pourriel}=\text{vrai}) = 0.4$, $P(\text{Inconnu}=\text{vrai} | \text{Pourriel}=\text{vrai}) = 0.6$
- On aurait tous les ingrédients pour calculer les $P(\text{Pourriel}, \text{Inconnu})$:
 - ◆ $P(\text{Pourriel}=\text{faux}, \text{Inconnu}=\text{vrai}) = P(\text{Inconnu}=\text{vrai} | \text{Pourriel}=\text{faux}) P(\text{Pourriel}=\text{faux})$
 $= 0.1 * 0.8 = 0.08$
 - ◆ $P(\text{Pourriel}=\text{vrai}, \text{Inconnu}=\text{vrai}) = P(\text{Inconnu}=\text{vrai} | \text{Pourriel}=\text{vrai}) P(\text{Pourriel}=\text{vrai})$
 $= 0.6 * 0.2 = 0.12$

Règle de Bayes

- $P(X|Y) = P(Y|X)P(X)/P(Y)$
- Donne une probabilité **diagnostique** à partir d'une probabilité **causale** :
 - ◆ $P(Cause|Effect) = P(Effect|Cause) P(Cause) / P(Effect)$

Règle de Bayes

- $P(X|Y) = P(Y|X)P(X)/P(Y)$
- Donne une probabilité **diagnostique** à partir d'une probabilité **causale** :
 - ◆ $P(Cause|Effet) = P(Effet|Cause) P(Cause) / P(Effet)$
- On pourrait calculer $P(Pourriel=faux | Inconnu=vrai)$:
 - ◆ $P(\neg pourriel | inconnu)$
 $= P(\neg pourriel, inconnu) / P(inconnu)$
 $= P(\neg pourriel, inconnu) / (P(inconnu, \neg pourriel) + P(inconnu, pourriel))$
 $= \alpha P(inconnu | \neg pourriel) P(\neg pourriel)$
 $= 0.08 / (0.08 + 0.12) = \mathbf{0.4}$
- On appelle $P(Pourriel)$ une **probabilité a priori**
 - ◆ c'est notre croyance p/r à la présence d'une Pourriel **avant** toute observation
- On appelle $P(Pourriel | Inconnu)$ une probabilité a **posteriori**
 - ◆ c'est notre croyance mise à jour après avoir observé *Inconnu*
- **La règle de Bayes** lie ces deux probabilités ensemble
 - ◆ $\underline{P(\neg pourriel | inconnu)} = \alpha P(inconnu | \neg pourriel) \underline{P(\neg pourriel)}$

$Pourriel=faux \Leftrightarrow \neg pourriel$
 $Pourriel=vrai \Leftrightarrow pourriel$

Indépendance

- Soit les variables A et B , elles sont **indépendantes** si et seulement si
 - ◆ $P(A|B) = P(A)$ ou
 - ◆ $P(B|A) = P(B)$ ou
 - ◆ $P(A, B) = P(A) P(B)$

Indépendance

- Soit les variables A et B , elles sont **indépendantes** si et seulement si
 - ◆ $P(A|B) = P(A)$ ou
 - ◆ $P(B|A) = P(B)$ ou
 - ◆ $P(A, B) = P(A) P(B)$
- Exemple : $P(\text{Pluie}, \text{Pourriel}) = P(\text{Pluie}) P(\text{Pourriel})$

<i>Pluie</i>	<i>Pourriel</i>	Probabilité
<i>vrai</i>	<i>vrai</i>	0.03
<i>vrai</i>	<i>faux</i>	0.27
<i>faux</i>	<i>vrai</i>	0.07
<i>faux</i>	<i>faux</i>	0.63

$$= P(\text{pluie}) P(\text{Pourriel}) = 0.3 * 0.1$$

$$= P(\text{pluie}) P(\neg \text{Pourriel}) = 0.3 * 0.9$$

$$= P(\neg \text{pluie}) P(\text{Pourriel}) = 0.7 * 0.1$$

$$= P(\neg \text{pluie}) P(\neg \text{Pourriel}) = 0.7 * 0.9$$

$P(\text{Pluie} = \text{vrai}) = 0.3$

$P(\text{Pourriel} = \text{vrai}) = 0.1$

Indépendance

- L'indépendance totale est puissante mais rare
- L'indépendance entre les variables permet de réduire la taille de la distribution de probabilités et rendre les inférences plus efficaces
 - ◆ dans l'exemple précédent, on n'a qu'à stocker en mémoire
 $P(\text{Pluie} = \text{vrai}) = 0.3$ et $P(\text{Pourriel} = \text{vrai}) = 0.1$, plutôt que la table au complet
- Mais il est rare d'être dans une situation où toutes les variables sont réellement indépendantes

<i>Pluie</i>	<i>Pourriel</i>	Probabilité
<i>vrai</i>	<i>vrai</i>	0.03
<i>vrai</i>	<i>faux</i>	0.27
<i>faux</i>	<i>vrai</i>	0.07
<i>faux</i>	<i>faux</i>	0.63

Indépendance conditionnelle

- Si je sais déjà que le courriel est un pourriel, ma croyance (probabilité) qu'il contienne un mot sensible ne dépend plus du fait que l'expéditeur me soit inconnu ou non :
 - ◆ $P(\text{Sensible} \mid \text{Inconnu}, \text{Pourriel}=\text{vrai}) = P(\text{Sensible} \mid \text{Pourriel}=\text{vrai})$
- On dit que *Sensible* est **conditionnellement indépendante** de *Inconnu* étant donné *Pourriel*, puisque :
 - ◆ $P(\text{Sensible} \mid \text{Inconnu}, \text{Pourriel}) = P(\text{Sensible} \mid \text{Pourriel})$
- Formulations équivalentes :
 - ◆ $P(\text{Inconnu} \mid \text{Sensible}, \text{Pourriel}) = P(\text{Inconnu} \mid \text{Pourriel})$
 - ◆ $P(\text{Inconnu}, \text{Sensible} \mid \text{Pourriel}) = P(\text{Inconnu} \mid \text{Pourriel}) P(\text{Sensible} \mid \text{Pourriel})$

Indépendance conditionnelle

- Réécrivons la distribution conjointe en utilisant la **règle de chaînage** (*chain rule*) :

$$\begin{aligned} P(\text{Inconnu}, \text{Sensible}, \text{Pourriel}) \\ &= P(\text{Inconnu} \mid \text{Sensible}, \text{Pourriel}) P(\text{Sensible}, \text{Pourriel}) \\ &= P(\text{Inconnu} \mid \text{Sensible}, \text{Pourriel}) P(\text{Sensible} \mid \text{Pourriel}) P(\text{Pourriel}) \\ &= P(\text{Inconnu} \mid \text{Pourriel}) P(\text{Sensible} \mid \text{Pourriel}) P(\text{Pourriel}) \end{aligned}$$

- C-à-d., $2 + 2 + 1 = 5$ **paramètres individuels/distincts**
- Dans des cas idéals, l'exploitation de l'indépendance conditionnelle réduit la complexité de représentation de la distribution conjointe de exponentielle ($O(2^n)$) en linéaire ($O(n)$)

En bref

- **Probabilité jointe** : $P(X_1, \dots, X_n)$
- **Probabilité marginale** : $P(X_i)$, $P(X_i, X_j)$, etc.
- **Probabilité conditionnelle** :
$$P(X_1, \dots, X_k \mid X_{k+1}, \dots, X_n) = \frac{P(X_1, \dots, X_k, X_{k+1}, \dots, X_n)}{P(X_{k+1}, \dots, X_n)}$$
- **Règle de chaînage** : $P(X_1, \dots, X_n) = \prod_{i=1..n} P(X_i \mid X_1, \dots, X_{i-1})$
- **Indépendance** : X_i et X_j sont indépendantes si
$$P(X_i, X_j) = P(X_i) P(X_j), \text{ ou } P(X_i \mid X_j) = P(X_i) \text{ ou } P(X_j \mid X_i) = P(X_j)$$
- **Indépendance conditionnelle** : X_i et X_j sont indépendante sachant X_k si
$$P(X_i, X_j \mid X_k) = P(X_i \mid X_k) P(X_j \mid X_k) \text{ ou } P(X_i \mid X_j, X_k) = P(X_i \mid X_k) \text{ ou } P(X_j \mid X_i, X_k) = P(X_j \mid X_k)$$
- **Règle de Bayes** :
$$P(X_1, \dots, X_k \mid X_{k+1}, \dots, X_n) = \frac{P(X_{k+1}, \dots, X_n \mid X_1, \dots, X_k) P(X_1, \dots, X_k)}{P(X_{k+1}, \dots, X_n)}$$

Autres types de variables aléatoires

- On s'est concentré sur des variables aléatoires Booléennes ou binaires
 - ◆ le **domaine**, c.-à-d. l'ensemble des valeurs possibles de la variable, était toujours *{vrai, faux}*
- On pourrait avoir d'autres types de variables, avec des domaines différents :
 - ◆ **Discrètes** : le domaine est énumérable
 - » $Météo \in \{soleil, pluie, nuageux, neige\}$
 - » lorsqu'on marginalise, on doit sommer sur toutes les valeurs :
$$P(Température) = \sum_{x \in \{soleil, pluie, nuageux, neige\}} P(Température, Météo=x)$$
 - ◆ **Continues** : le domaine est continu (par exemple, l'ensemble des réels)
 - » exemple : $PositionX = 4.2$
 - » le calcul des probabilités marginales nécessite des intégrales

Classifieur bayésien naïf

- Le classifieur (modèle) bayésien naïf est défini comme suit

$$P(\text{Cause}, \text{Effet}_1, \dots, \text{Effet}_n) = P(\text{Cause}) = \prod_{i=1..n} P(\text{Effet}_i \mid \text{Cause})$$

- Naïf parce qu'on suppose l'indépendance conditionnel. Mais fonctionne dans beaucoup d'applications

Classifieur bayésien naïf

- Le modèle (Classifieur) bayésien naïf est défini comme suit

$$P(\text{Cause}, \text{Effet}_1, \dots, \text{Effet}_n) = P(\text{Cause}) \prod_{i=1..n} P(\text{Effet}_i | \text{Cause})$$

- Pour l'appliquer, en général, on observe des effets (e) et on veut diagnostiquer la cause.
- Noton **E=e** les effets observés. On a vu que $P(\text{Cause} | \mathbf{e}) = \alpha \sum_y P(\text{Cause}, \mathbf{e}, y)$
- On a donc:

$$\begin{aligned} P(\text{Cause} | \mathbf{e}) &= \alpha \sum_y P(\text{Cause}) P(y | \text{Cause}) \prod_{j=1..n} P(e_j | \text{Cause}) \\ &= \alpha P(\text{Cause}) \prod_{j=1..n} P(e_j | \text{Cause}) \sum_y P(y | \text{Cause}) \\ &= \alpha P(\text{Cause}) \prod_{j=1..n} P(e_j | \text{Cause}) \end{aligned}$$

Classification de documents

- Classifieur bayésien naïf

$$P(\text{Cause} | e) = \alpha P(\text{Cause}) \prod_{j=1..n} P(e_j | \text{Cause})$$

- Classification de documents: étant donné un document texte, déterminer dans laquelle des catégories prédéfinie il appartient (ex: sport, économie)
- Exemples de textes (documents):
 - ◆ Apple a fait état jeudi d'un chiffre d'affaires et d'un bénéfice net supérieur aux attentes pour le trimestre allant d'octobre à décembre l'année dernière, la forte hausse des ventes d'iPhone, notamment en Chine, ayant plus que compensé les difficultés des chaînes d'approvisionnement ... (*Tiré de Radio Canada / Économie – 2022-01-08*)
 - ◆ Le Canada s'est rapproché davantage de son objectif en défaisant le Honduras 2-0, jeudi, en match de qualification pour la Coupe du monde au Qatar (*Tiré de Radio Canada / Sport – 2022-01-08*)

Classification de documents

- Classifieur bayésien naïf

$$P(\text{Cause} | \mathbf{e}) = \alpha P(\text{Cause}) \prod_{j=1..n} P(e_j | \text{Cause})$$

- Étant donné un document, déterminer dans laquelle des catégories prédéfinie il appartient (e.g., sport, politique, économie, etc.)
 - ◆ **Cause** correspond à la catégorie (classe) des documents (sport, politique, etc.)
 - ◆ e_j correspond à la présence ou absence de certains mots clés, keyWord_i .
 - ◆ Donc $\mathbf{e} \equiv \{\text{keyWord}_1, \dots, \text{keyWord}_n\}$, c.-à-d, les mots-clés observés

$$P(\text{Class} | \text{keyWord}_1, \dots, \text{keyWord}_n) = \alpha P(\text{Class}) \prod_{j=1..n} P(\text{keyWorld}_i | \text{Class})$$

- Le modèle bayésien naïf consiste des probabilités à priori $P(\text{Class})$ et des probabilités conditionnelles $P(\text{KeyWorld}_i | \text{Class})$.

Classification de documents

$$P(\text{Category} | \text{ObservedKeyWords}) = \alpha P(\text{Category}) \prod_{j=1..n} P(\text{HasWorld}_j | \text{Category})$$

- Le modèle bayésien naïf consiste des probabilités à priori $P(\text{Category})$ et des probabilités conditionnelles $P(\text{HasWorld}_j | \text{Category})$.
- Pour classifier un document
 - ◆ On vérifie quels mots clés apparaissent dans le document, ce qui donne ObservedKeywords
 - ◆ On applique ensuite l'équation pour obtenir la distribution des probabilités à postériori des catégories, c.-à-d., $P(\text{Category} | \text{ObservedKeyWords})$
 - ◆ On choisit finalement $\text{argmax}_c P(\text{Category} = c | \text{ObservedKeyWords})$, c.-à-d., la catégorie avec la probabilité à postériori la plus élevée.

Classification de documents

$$P(\textit{Category} | \textit{ObservedKeywords}) = \alpha P(\textit{Catgeory}) \prod_{j=1..n} P(\textit{HasWorld}_j | \textit{Category})$$

- Le modèle bayésien naïf consiste des probabilités à priori $P(\textit{Category})$ et des probabilités conditionnelles $P(\textit{HasWorld}_j | \textit{Category})$.
- Pour apprendre le modèle:
 - ◆ $P(\textit{Category} = c)$ est la fraction des documents de cette catégorie vue jusqu'à présent.
 - ◆ $P(\textit{HasWord}_i | \textit{Category} = c)$ est la fraction de documents de catégorie c de la catégorie qui contient le mot \textit{Word}_i .

Conclusion

- La théorie des probabilités est un cadre mathématique permettant de faire des inférences explicables facilement.
- Les algorithmes d'IA probabilistes utilisent des modèles probabilistes graphiques qui sont plus efficace que la théorie des probabilité de base:
 - ◆ Réseau bayésien
 - ◆ Réseau bayésien dynamique
 - » Modèle de Markov caché
 - » Filtre de particule

En bref

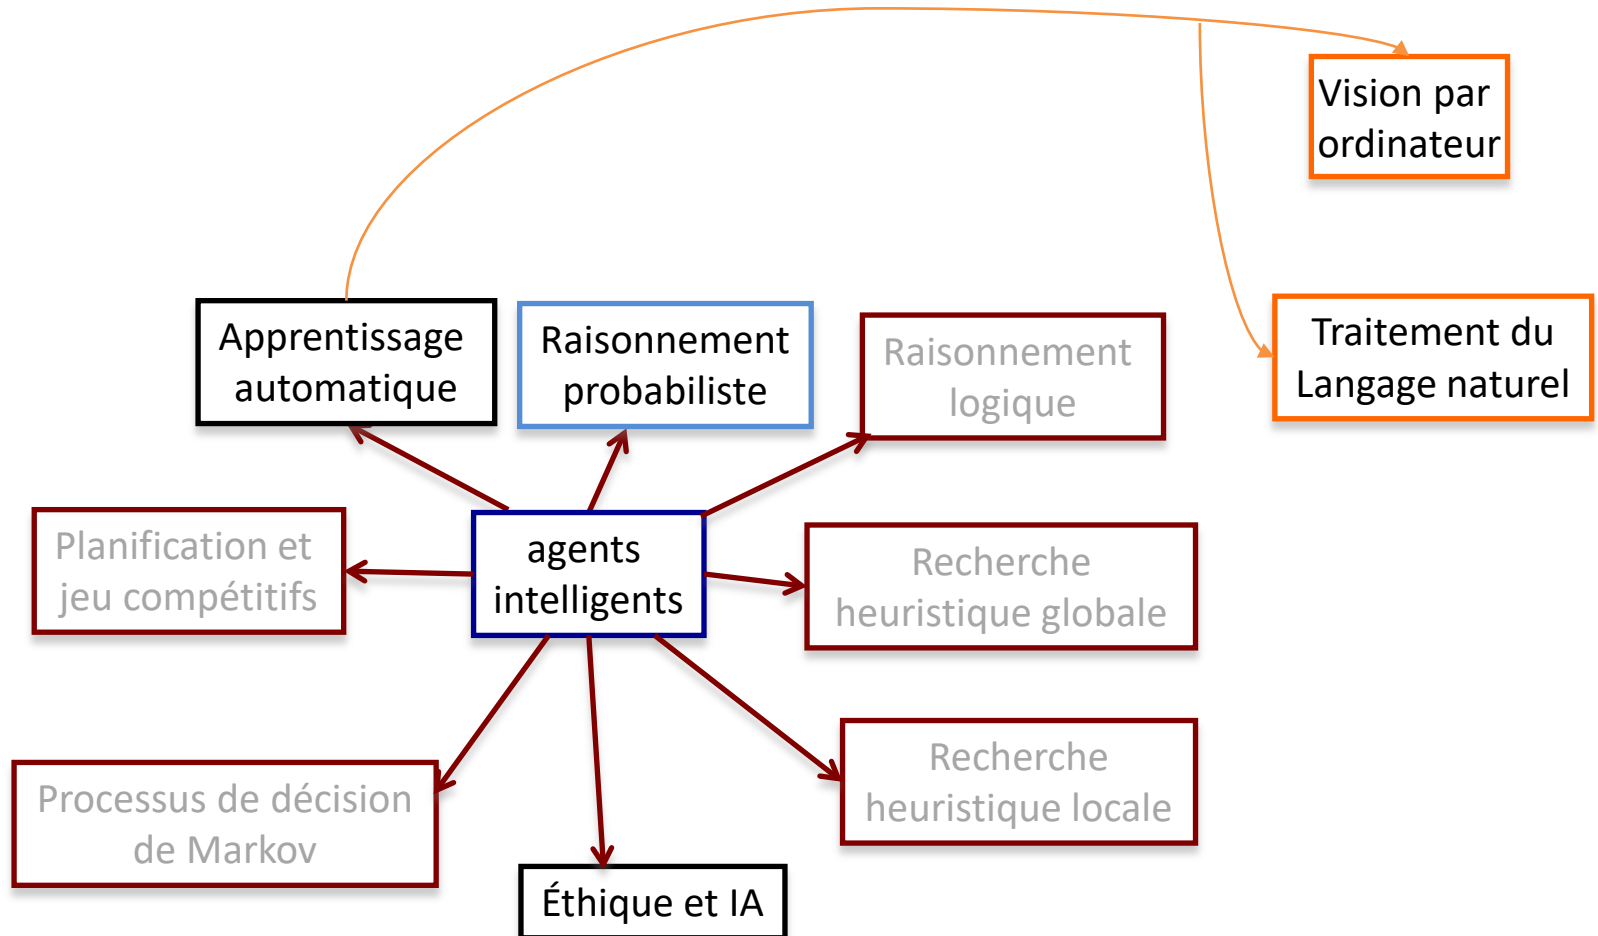
- Probabilité jointe : $P(X_1, \dots, X_n)$
- Probabilité marginale : $P(X_i)$, $P(X_i, X_j)$, etc.
- Probabilité conditionnelle : $P(X_1, \dots, X_i | X_{i+1}, \dots, X_n) = \frac{P(X_1, \dots, X_i, X_{i+1}, \dots, X_n)}{P(X_{i+1}, \dots, X_n)}$
- Règle de chaîne : $P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i | X_1, \dots, X_{i-1})$
- Indépendance : X et Y sont indépendantes si $P(X, Y) = P(X)P(Y)$, ou $P(X|Y) = P(X)$ ou $P(Y|X) = P(Y)$
- Indépendance conditionnelle : X et Y sont indépendants sachant Z si $P(X, Y|Z) = P(X|Z)P(Y|Z)$ ou $P(X|Y, Z) = P(X|Z)$ ou $P(Y|X, Z) = P(Y|Z)$
- Règle de Bayes : $P(X_1, \dots, X_i | X_{i+1}, \dots, X_n) = \frac{P(X_{i+1}, \dots, X_n | X_1, \dots, X_i) P(X_1, \dots, X_i)}{P(X_{i+1}, \dots, X_n)}$

IFT615 Hugo Larochelle et Froduald Kabanza 36

Sujets couverts par le cours

Concepts et algorithmes

Applications



Vous devriez être capable de...

- À partir d'une distribution conjointe ou des distributions conditionnelles et a priori nécessaires :
 - ◆ calculer une probabilité conjointe
 - ◆ calculer une probabilité marginale
 - ◆ déterminer si deux variables sont indépendantes
 - ◆ déterminer si deux variables sont conditionnellement indépendantes sachant une troisième
 - ◆ Appliquer la règle du chainage
 - ◆ Appliquer la règle de Bayes
- Expliquer le classifieur bayésien naïf et son application à la classification de documents

